

P2 - Balanceo de carga

Servidores Web de Altas Prestaciones

UGR - ETSIIT

Torres Ramos, Juan Luis

17 abril de 2024

Índice

Índice	1
Tareas Básicas - B1 Preparación del Entorno de Trabajo	1
Tareas Básicas - B2 Configuración de Nginx como Balanceador de Carga	3
Tareas Básicas - B3 Implementación del escenario de Ningx con Docker Compose	7
Tareas Básicas - B4 Verificación y Pruebas del escenario de Nginx	9
Tareas Básicas - B5 Configuración de HAProxy como Balanceador de Carga	12
Tareas Básicas - B6 Implementación del escenario de HAProxy con Docker Compose	15
Tareas Básicas - B7 Verificación y Pruebas del escenario de HAProxy	16
Tareas Avanzada - A1 Configuraciones Avanzadas de Nginx	19
Tareas Avanzada - A2 Configuraciones Avanzadas de HAProxy	21
Tareas Avanzada - A3 Experimentación con Diferentes Balanceadores de Carga	24
Tareas Avanzada - A4 Investigación y Pruebas de Tolerancia a Fallos	28
Tareas Avanzada - A5 Automatización de escalado del escenario	32

Tareas Básicas - B1 Preparación del Entorno de Trabajo

Voy a crear directorios específicos para los archivos de configuración de los balanceadores:

- 1. P2-tuusuariougr-nginx para trabajar con los archivos de configuración de nginx
- 2. P2-tuusuariougr-haproxy para trabajar con los archivos de configuración de HAProxy.

```
mkdir P2-juanluis-nginx
mkdir P2-juanluis-haproxy
```

Quedaría de la siguiente forma

Tareas Básicas - B2 Configuración de Nginx como Balanceador de Carga

Trabajamos desde la carpeta de nginx. Voy a redactar el Dockerfile para crear una imagen personalizada de Nginx a partir de la imagen oficial. Además voy a escribir el archivo de configuración nginx.conf con la estrategia de balanceo round-robin.

Este es el dockerfile para ejecutar la imagen nginx, donde lo expongo en el puerto 80

```
FROM nginx:latest

COPY nginx.conf /etc/nginx/nginx.conf

EXPOSE 80

# en primer plano
CMD [ "nginx", "-g", "daemon off;"]

# en segundo plano
# CMD ["nginx"]
```

Para ejecutarlo

```
docker build -t juanluistr-nginx-image:p2 -f DockerfileNginx_juanluisUGR .
```

Pasamos a crear el archivo de configuración *nginx.conf*. Previamente hemos configurado la imagen nginx anterior solo comentando la parte del copiar nginx.conf. Con ello se generará un nginx.conf por defecto. Ejecutamos la imagen con un *docker run*. Dentro del contenedor,en el bash, vamos a la dirección /etc/nginx/ y hacemos un cat al archivo *nginx.conf* para copiar el de por defecto. Ya teniendo un *nginx.conf* por defecto vamos a modificarlo para que tenga una configuración de balanceo de carga aplicando round-robin, asociamos nuestros servicios habilitamos estadísticas en /estadisticas_juanluis y aplicamos configuraciones de registro de acceso y errores.

El archivo nginx quedaría como sigue:

```
user nginx;
worker_processes auto;
error_log /var/log/nginx/error.log notice;
       /var/run/nginx.pid;
events {
   worker connections 1024;
http {
  upstream backend_juanluis{
   # algoritmo balanceo (loast_conn;round-robin; etc.)
  # round-robin se usa por defecto
  least_conn; # para el apartado A1
  server 192.168.10.9;
  server 192.168.10.2;
  server 192.168.10.3 weight=5;
  server 192.168.10.4;
  server 192.168.10.5;
   server 192.168.10.6 weight=10;
   server 192.168.10.7;
  server 192.168.10.8;
  # etc
   }
   server {
      listen 80;
      server_name nginx_juanluis;
       access_log /var/log/nginx/nginx_juanluis.access.log;
       error_log /var/log/nginx/nginx_juanluis.error.log;
       location / {
           proxy pass http://backend juanluis;
           proxy_set_header Cookie $http_cookie;
           proxy_hide_header Set-Cookie;
       location /estadisticas_juanluis {
           stub_status on;
   }
}
```

El servidor Nginx escucha en el puerto 80 y actúa como balanceador de carga. Todas las solicitudes que entran son procesadas por el balanceador y luego las enviamos a los servidores backend definidos de la práctica 1 que hemos definido en la sección upstream. Round robin se establece por defecto, en /estadisticas_juanluis hemos configurado un monitor de estadísticas y los errores y los accesos se encuentran en las variables /var/log/nginx/nginx_juanluis.access.log y /var/log/nginx/nginx_juanluis.error.log.

Tareas Básicas - B3 Implementación del escenario de Nginx con Docker Compose

Vamos a reutilizar el DockerfileApache de la práctica 1 para los contenedores de Apache, y tenemos que modificar el dockerfile de la práctica anterior para, añadir a cada web una ip propia (igual a la que definimos en upstream) y luego añadimos el servicio "balanceador-nginx".

El nuevo archivo dockerfile quedaría de la siguiente forma

```
version: '3.8'
services:
balanceador-nginx:
   build:
     context: .
     dockerfile: DockerfileNginx juanluisUGR
   image: juanluistr-nginx-image:p2
   volumes:
     - ./nginx_conf:/etc/nginx/conf.d
   ports:
     - "3000:80"
   networks:
     red web:
       ipv4 address: 192.168.10.50
   depends on:
     - web1
     - web2
     - web3
     - web4
     - web5
     - web6
     - web7
     - web8
web1:
   image: juanluistr-apache-image:p1
   privileged: true
   build:
     dockerfile: DockerfileApache juanluisUGR
     - ./web_usuarioUGR:/var/www/html
   networks:
```

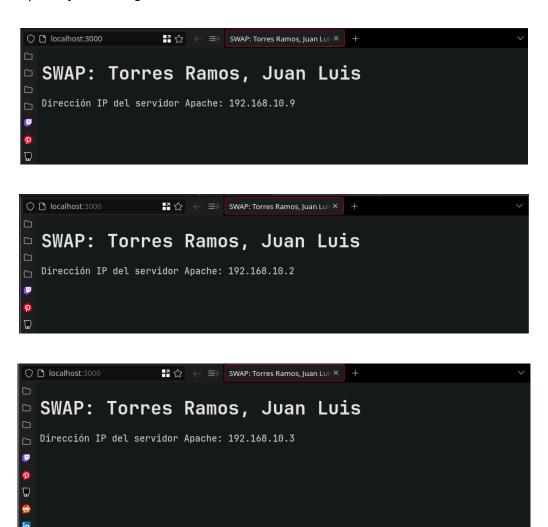
```
red_web:
       ipv4_address: 192.168.10.9
     red_servicios:
       ipv4_address: 192.168.20.9
   #ports:
   # - "8081:80"
# ... (el resto de webX son similares a web1)
networks:
 red_web:
   driver: bridge
   ipam:
    driver: default
    config:
       - subnet: 192.168.10.0/24
 red_servicios:
   driver: bridge
   ipam:
    driver: default
    config:
      - subnet: 192.168.20.0/24
```

Tareas Básicas - B4 Verificación y Pruebas del escenario de Nginx

Ahora desplegamos los servicios

```
docker compose up -d
```

Vamos a comprobar que los servicios están activos y que Nginx distribuye las solicitudes correctamente. Habiendo quitado los puertos de cada WebX, solo podremos acceder al balanceador. Accedemos al balanceador en el http://localhost:3000/. Ahí si vamos actualizando la página , con la política round robin iremos recorriendo cada servicio del backend que hayamos asignado al balanceador.



Por último entramos al monitor de estadísticas que hemos configurado en http://localhost:3000/estadisticas juanluis

```
O localhost:3000/estadisticas_ju ≥ 12 to ← ⇒ localhost:3000/estadisticas_ju × + 

Active connections: 2 server accepts handled requests 4 4 8 Reading: 0 Writing: 1 Waiting: 1
```

Nos indica que, hay 2 conexiones activas del servidor, 8 solicitudes en total han sido procesadas por el servidor y que 4 han sido aceptadas y 4 han sido manejadas por el servidor. El balanceador actualmente está escribiendo una respuesta al cliente y esta esperando 1 conexión del siguiente WebX. Si actualizamos, pasaría a leer el siguiente WebX y quedaría de la forma:

```
O □ localhost:3000/estadisticas_jus ♣2 ☆ ← ⇒ localhost:3000/estadisticas_jus× +

Active connections: 1
server accepts handled requests
5 5 9
Reading: 0 Writing: 1 Waiting: 0
```

Análisis propuesta IA

¿Qué significa las estadísticas de esta directiva stub_status?

Estas estadísticas son proporcionadas por la directiva stub_status de Nginx y proporcionan información sobre el estado actual del servidor. Aquí está el significado de cada línea:

Active connections: 2: Indica el número total de conexiones activas en el servidor en ese momento. En este caso, hay 2 conexiones activas.

server accepts handled requests: Estas tres métricas indican la cantidad de conexiones que el servidor ha aceptado, la cantidad de conexiones que ha manejado y el número total de solicitudes procesadas.

Accepted connections (aceptadas): 4 conexiones han sido aceptadas por el servidor desde que se inició.

Handled connections (manejadas): 4 conexiones han sido manejadas completamente por el servidor, es decir, se han completado todas las operaciones de lectura y escritura para estas conexiones.

Requests (solicitudes): 8 solicitudes en total han sido procesadas por el servidor.

Reading: 0 Writing: 1 Waiting: 1: Estas tres métricas representan el estado actual de las conexiones en el servidor.

Reading (Leyendo): El número de conexiones que están actualmente leyendo una solicitud del cliente.

Writing (Escribiendo): El número de conexiones que están actualmente escribiendo una respuesta al cliente.

Waiting (Esperando): El número de conexiones que están en estado de espera, por ejemplo, esperando en la cola para ser procesadas.

En resumen, estas estadísticas proporcionan una instantánea del rendimiento del servidor Nginx en términos de conexiones activas, solicitudes procesadas y el estado actual de las conexiones en lectura, escritura y espera. Son útiles para monitorear el rendimiento y la salud del servidor en tiempo real

Con chat gpt me ha ayudado a entender mejor qué es lo que devuelve mi monitoreo en Nginx. Me dice que devuelve cada variable y así me aseguro que mi respuesta es correcta porque viendo directamente desde el monitor de estadísticas puedo intuir que significa cada variable, pero con chat gpt me aseguro que vale cada variable.

Tareas Básicas - B5 Configuración de HAProxy como Balanceador de Carga

Vamos ahora a trabajar desde la carpeta HAProxy para implementar un balanceador de carga con este servicio, vamos a redactar el dockerfile para crear una imagen de HAProxy a partir de la imagen oficial.

Imagen Dockerfile Haproxy

```
# Usa la imagen oficial de HAProxy como base
FROM haproxy:latest

# Copia tu configuración personalizada de HAProxy al contenedor
COPY haproxy.cfg /usr/local/etc/haproxy/haproxy.cfg

# Exponer el puerto 80 (o cualquier otro puerto que uses en tu configuración)
EXPOSE 80

# Comando predeterminado para ejecutar HAProxy
CMD ["haproxy", "-f", "/usr/local/etc/haproxy/haproxy.cfg"]
```

Antes de construir vamos a pasar a crear el haproxy.cfg

```
docker build -t juanluistr-haproxy-image:p2 -f
DockerfileHaproxy_juanluisUGR .
```

Análisis propuesta IA

```
redactar el dockerfile para crear una imagen de HAProxy a partir de la imagen oficial

Aquí tienes un Dockerfile básico para crear una imagen de HAProxy a partir de la imagen oficial:

Dockerfile

# Usa la imagen oficial de HAProxy como base

FROM haproxy:latest

# Copia tu configuración personalizada de HAProxy al contenedor

COPY haproxy.cfg /usr/local/etc/haproxy/haproxy.cfg
```

```
# Opcional: si necesitas agregar archivos adicionales, como certificados
SSL, puedes copiarlos aquí
# COPY certs/ /usr/local/etc/haproxy/certs/
# Opcional: si necesitas instalar herramientas adicionales dentro del
contenedor, puedes hacerlo aquí
# RUN apt-get update && apt-get install -y tu-herramienta-adicional
# Exponer el puerto 80 (o cualquier otro puerto que uses en tu
configuración)
EXPOSE 80
# Comando predeterminado para ejecutar HAProxy
CMD ["haproxy", "-f", "/usr/local/etc/haproxy/haproxy.cfg"]
Asegúrate de tener un archivo haproxy.cfg en el mismo directorio que tu
Dockerfile, o ajusta la ruta en la instrucción COPY si está en un
directorio diferente. Este archivo debe contener tu configuración
personalizada de HAProxy.
Después de crear tu Dockerfile, puedes construir la imagen ejecutando el
siguiente comando en la misma carpeta que contiene el Dockerfile:
bash
docker build -t mi-haproxy .
Esto construirá la imagen de HAProxy según tu Dockerfile y le asignará el
nombre mi-haproxy.
Recuerda que debes tener instalado Docker en tu sistema para poder
construir y ejecutar contenedores Docker.
```

Me genera una imagen funcional y no le he tenido que hacer ninguna modificación, me ayuda a saber path importantes a la hora de usar Haproxy. Chat gpt a la hora de crear imágenes sencillas es muy funcional.

Este es el archivo de configuracion haproxy.cfg

```
frontend frontend_juanluisUGR
   bind *:80
   default_backend backend_juanluisUGR
   timeout client 60s
backend backend_juanluisUGR
   balance roundrobin
   timeout connect 5s
   timeout server 30s
   server web1 192.168.10.9:80 maxconn 32 check
   server web2 192.168.10.2:80 maxconn 32 check
   server web3 192.168.10.3:80 maxconn 32 check
   server web4 192.168.10.4:80 maxconn 32 check
   server web5 192.168.10.5:80 maxconn 32 check
   server web6 192.168.10.6:80 maxconn 32 check
   server web7 192.168.10.7:80 maxconn 32 check
   server web8 192.168.10.8:80 maxconn 32 check
listen stats
   bind *:9000
   mode http
   stats enable
   stats uri /estadisticas_juanluisUGR
   stats auth juanluisUGR:SWAP1234
   timeout client 60s
```

Tareas Básicas - B6 Implementación del escenario de HAProxy con Docker Compose

Tenemos ahora que crear el servicio en docker-compose, tenemos que exponer tanto el frontend que está en el puerto 80 como stats que está en el puerto 9000. Quedaría de la siguiente forma

Lo suyo es que para el frontend exponerlo en el puerto 80:80 en vez de 3000:80 o 8080:80 pero tengo en uso el puerto 80.

Quedaría de la siguiente forma en nuevo servicio balanceador-haproxy.

```
services:
balanceador-haproxy:
build:
    context: .
    dockerfile: DockerfileHaproxy_juanluisUGR
image: juanluistr-haproxy-image:p2
privileged: true
volumes:
    - ./haproxy.cfg:/usr/local/etc/haproxy/haproxy.cfg:ro
ports:
    - "3000:80"
    - "9000:9000"
```

luego podemos confirmar con un logs del contenedor que funciona correctamente, obtendremos:

```
2024-04-18 18:00:37 [NOTICE] (1) : New worker (8) forked 2024-04-18 18:00:37 [NOTICE] (1) : Loading success.
```

Tareas Básicas - B7 Verificación y Pruebas del escenario de HAProxy

Desplegamos nuestra granja web con el balanceador haproxy

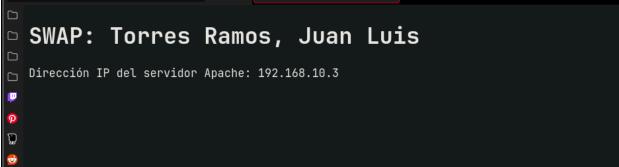
```
docker-compose up -d
```

Ahora para ver nuestros servidores tenemos que acceder al http://localhost:3000/ y para ver las estadísticas será en http://localhost:9000/estadisticas juanluisUGR, accedemos con el usuario juanluisUGR y la contraseña SWAP1234.

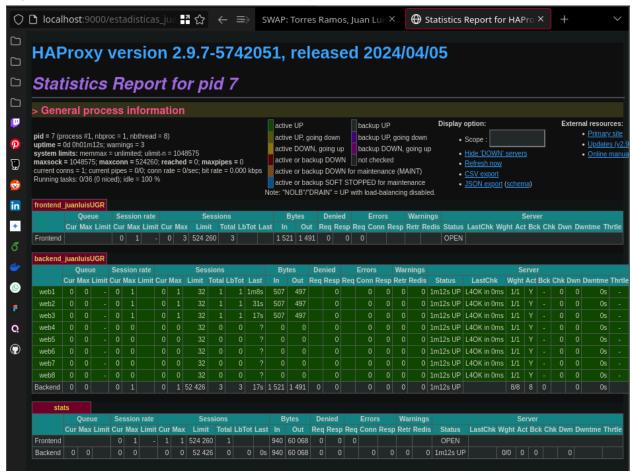
En http://localhost:3000/ podemos acceder a los servidores del backend, e irá recorriendo los según la política round robin que hemos definido







Viendo las estadísticas podemos ver que todos los servidores están up y en la variable session last podemos ver la última vez que se ha accedido a dicho servidor. Vamos recorriendo en http://localhost:3000/ viendo todos los server y se irá actualizando dicha variable de acceso:



Cada vez que se despliega la granja web puede ocurrir que algún servidor no sea reconocido por el Haproxy. Lo he comentado ya en clase pero no se ha podido solucionar completamente .Intuyo que puede ser que se ejecute antes el servicio del balanceador antes que algún WebX. Para solucionar este problema, aunque hay veces que puede pasar, hay que añadir más tiempo de timeout client tanto en el frontend como el listen stat, mínimo unos 60s y la mayoría de despliegue deberían realizarse correctamente. Si algún servicio del backend no ha sido detectado por el balanceador, borrar el conjunto de contenedores que genera docker-compose y volver a desplegarlo

Análisis propuesta IA

im accesing form port 9000 but it says that the servers are not checked why

ChatGPT

If HAProxy is reporting that the servers are not checked, even though they are up and running, it suggests that HAProxy is unable to successfully perform health checks on the backend servers. Here are some potential reasons and troubleshooting steps to resolve the issue:

Health Check Configuration: Review your health check configuration in HAProxy to ensure it's correctly configured and appropriate for your backend server setup. Pay attention to parameters such as inter, rise, and fall in your server definitions. Firewall or Network Issues: Check for any firewall rules or network issues that might be blocking HAProxy from communicating with the backend servers on the health check ports. Ensure that the health check ports are accessible from the HAProxy container.

Backend Server Configuration: Verify that the backend servers are properly configured to respond to the health check requests sent by HAProxy. Ensure that the servers are configured to respond to health checks on the correct port and path. Server Reachability: Ensure that HAProxy can reach the backend servers on the specified IP addresses and ports. You can test this by trying to access the backend servers directly from the HAProxy container or by using tools like telnet or nc. Logging and Debugging: Check the HAProxy logs for any error messages or warnings related to the health checks. Increase the logging level if necessary to get more detailed information about what might be going wrong.

Server Load or Performance Issues: If the backend servers are under heavy load or experiencing performance issues, they may not be able to respond to health check requests in a timely manner. Monitor the server's performance and ensure that it can handle the health check load.

By addressing these potential issues and troubleshooting accordingly, you should be able to identify and resolve the problem with HAProxy not successfully checking the backend servers.

Al principio, con el haproxy.cfg, no salía que los servidores estuviesen en verde, si se actualizaba la variable de acceso pero no si estaban siendo chequeados o no. Pregunté varias veces a chat gpt pero solo respondía con que revisará la configuración de mis archivos a ver si tenía algún error. Luego se encuentra en esta página web y solo necesita añadir el tag check en cada server del backend. Es importante con chatgpt usar bien los prompt y preguntarle cosas en especifico, entender que es lo que le preguntas si no tardaras mas tiempo en encontrar la solución.

https://www.haproxy.com/blog/how-to-enable-health-checks-in-haproxy

Tareas Avanzada - A1 Configuraciones Avanzadas de Nginx

Vamos a modificar Nginx para aplicar una política de balanceo de conexiones activas con ponderaciones. Seguimos los pasos del siguiente enlace y añadimos que el web3 tenga peso 5 y web6 tenga peso 10 (los pesos también se pueden usar en la política round robin). https://docs.nginx.com/nginx/admin-quide/load-balancer/http-load-balancer/

nginx.conf

```
user nginx;
worker_processes auto;
error_log /var/log/nginx/error.log notice;
pid
        /var/run/nginx.pid;
events {
   worker connections 1024;
http {
   upstream backend juanluis{
   # algoritmo balanceo (loast conn;round-robin; etc.)
   # round-robin se usa por defecto
   least_conn; # para el apartado A1
   server 192.168.10.9;
   server 192.168.10.2;
   server 192.168.10.3 weight=5;
   server 192.168.10.4;
   server 192.168.10.5;
   server 192.168.10.6 weight=10;
   server 192.168.10.7;
   server 192.168.10.8;
   # etc
   }
   server {
       listen 80;
       server_name nginx_juanluis;
```

```
access_log /var/log/nginx/nginx_juanluis.access.log;
error_log /var/log/nginx/nginx_juanluis.error.log;

location / {
    proxy_pass http://backend_juanluis;
    proxy_set_header Cookie $http_cookie;
    proxy_hide_header Set-Cookie;
}

location /estadisticas_juanluis {
    stub_status on;
}
```

Volvemos a construir la imagen y desplegar los contenedores .Ahora cuando recorremos los WebX nos da el siguiente resultado como ejemplo:

```
192.168.10.6

192.168.10.6

192.168.10.9

192.168.10.6

192.168.10.3

192.168.10.2

etc
```

Podemos ver que ahora el comportamiento da más prioridad a acceder a Web6 y luego a Web3 y luego al resto de servidores. Como las conexiones activas de cada servidor son las mismas, actuará como round robin a fin de cuentas(es decir que least_conn no tiene relevancia), pero con los pesos cambia la cosa. Es un balance basado en pesos/ponderaciones con el menor número de conexiones posibles.

Tareas Avanzada - A2 Configuraciones Avanzadas de HAProxy

Vamos a modificar Haproxy para aplicar una política source, donde se distribuye las solicitudes de manera uniforme entre los servidores backend basándose en la dirección IP de origen de la solicitud, todas las solicitudes provenientes de una misma dirección IP serán dirigidas al mismo servidor backend.

El archivo de configuración queda de la siguiente forma

```
frontend frontend juanluisUGR
  bind *:80
  default backend backend juanluisUGR
  timeout client 30s
 backend backend juanluisUGR
  balance source
                        # Use 'balance source' to achieve similar IP-based
hashing
  hash-type consistent
  timeout connect 5s
  timeout server 30s
  server web1 192.168.10.9:80 maxconn 32 check
  server web2 192.168.10.2:80 maxconn 32 check
  server web3 192.168.10.3:80 maxconn 32 check
  server web4 192.168.10.4:80 maxconn 32 check
  server web5 192.168.10.5:80 maxconn 32 check
  server web6 192.168.10.6:80 maxconn 32 check
  server web7 192.168.10.7:80 maxconn 32 check
  server web8 192.168.10.8:80 maxconn 32 check
 listen stats
  bind *:9000
  mode http
  stats enable
  stats uri /estadisticas_juanluisUGR
  stats auth juanluisUGR:SWAP1234
  timeout client 10s
```

construimos la imagen y desplegamos la granja con el balanceador Estudiamos ahora un ejemplo de salida:

```
192.168.10.7
192.168.10.7
192.168.10.7
192.168.10.7
```

Confirmamos lo que hemos dicho anteriormente. Ahora todas las solicitudes provenientes de una misma dirección IP serán dirigidas al mismo servidor backend, en este caso es el 192.168.10.7.

Análisis propuesta IA

IP address.

```
try another similar option like ip hash
I see. It appears there might be a difference in the way HAProxy 2.9.7 handles
the balance hash directive compared to later versions.
In your version, you might need to use a different approach. Instead of balance
hash, you can use balance source to achieve a similar effect. Here's the
modified configuration:
plaintext
backend backend juanluisUGR
balance source
                       # Use 'balance source' to achieve similar IP-based
hashing
      hash-type consistent
      timeout connect 5s
      timeout server 30s
      server web1 192.168.10.9:80 maxconn 32 check
      server web2 192.168.10.2:80 maxconn 32 check
      server web3 192.168.10.3:80 maxconn 32 check
      server web4 192.168.10.4:80 maxconn 32 check
      server web5 192.168.10.5:80 maxconn 32 check
      server web6 192.168.10.6:80 maxconn 32 check
      server web7 192.168.10.7:80 maxconn 32 check
      server web8 192.168.10.8:80 maxconn 32 check
With this modification, HAProxy will still use the source IP address for
hashing, effectively distributing requests based on the client's IP address.
This should resolve the configuration error you encountered.
```

Al principio chat gpt me indicaba que usase balance IP-hash, lo que sucedía es que al final actuaba como una política round robin , o no se aplicaba la política hash, por lo que le pregunte a chat gpt que me diera otro acercamiento, en este caso funcionó con una política similar balance source añadiendo la directiva hash-type consistent. Hay veces que la primera solución de chat gpt no es la correcta, por lo que es recomendable probar otros caminos

Tareas Avanzada - A3 Experimentación con Diferentes Balanceadores de Carga

Vamos a aplicar el balanceador gobettween https://leo.leung.xyz/wiki/Gobetween
Vamos a usar la imagen directamente en docker

En docker-compose añadimos

```
version: '3.3'
services:
    gobetween:
    image: yyyar/gobetween
    ports:
        - "80:80"
        - "443:443"
    restart: always
    volumes:
        - ./config.toml:/etc/gobetween/conf/gobetween.toml
```

config file sera como config.toml

```
[servers.https]
bind = ":443"
protocol = "tcp"
balance = "weight"
max connections = 1000
client_idle_timeout = "10m"
backend_idle_timeout = "10m"
backend_connection_timeout = "2s"
[servers.https.discovery]
kind = "static"
static list = [
    "192.168.248.5:443 weight=1"
]
[servers.http]
bind = ":80"
protocol = "tcp"
balance = "weight"
```

```
max_connections = 1000
client_idle_timeout = "10m"
backend_idle_timeout = "10m"
backend_connection_timeout = "2s"

[servers.http.discovery]
kind = "static"
static_list = [
    "192.168.248.5:80 weight=1"
]
```

Lo único cuando vayamos a http://localhost:3000 nos saldrá un index (no he podido configurar esta parte), allí tendremos que acceder a web_usuario y luego otra vez a web_usuario. Allí ya nos aparecerá nuestro index.php y cada vez que actualicemos, irá mediante la política round robin, visitando nuestros servidores backend.



Análisis propuesta IA

```
crea un dockerfile que use la imagen de gobetween para implementar un
balanceador de carga, no uses alpine
Entendido, si prefieres no usar Alpine como base, podemos utilizar una
imagen más genérica. Aquí tienes un Dockerfile que utiliza la imagen
oficial de GoBetween desde Docker Hub:
Dockerfile
# Usa la imagen base de Debian
FROM debian:latest
# Instala dependencias necesarias
RUN apt-get update && apt-get install -y --no-install-recommends \
    ca-certificates \
    && rm -rf /var/lib/apt/lists/*
# Descarga y copia el archivo binario de GoBetween
ADD
https://github.com/yyyar/gobetween/releases/download/0.8.0/gobetween 0.8.0
linux amd64 /usr/local/bin/gobetween
# Asigna permisos de ejecución al archivo de GoBetween
RUN chmod +x /usr/local/bin/gobetween
# Puerto en el que escuchará el balanceador de carga
EXPOSE 80 443
# Comando por defecto al iniciar el contenedor
CMD ["gobetween", "--api=0.0.0.0:8888"]
Este Dockerfile descarga el archivo binario de GoBetween versión 0.8.0 para
Linux de la URL proporcionada y lo coloca en /usr/local/bin/gobetween.
Luego, asigna permisos de ejecución y expone los puertos 80 y 443 que serán
utilizados para el balanceo de carga. Finalmente, el comando por defecto al
iniciar el contenedor es gobetween --api=0.0.0.0:8888, lo que significa que
GoBetween escuchará en todas las interfaces en el puerto 8888. Puedes
modificar el comando según tus necesidades.
```

Cuidado con la aproximación que le damos. En este caso este no es el método que se recomiendan en gobetween. Recomiendan usar directamente la imagen dockerfile que les proporcionan, no crear la tuya misma. Yo he tenido problemas aquí a la hora de intentar usar mi propia imagen de gobetween. Este es un balanceador nuevo y hay que tener en cuenta que el chat apt a veces no está actualizado.

```
Configura el archivo config.toml anterior para aplicar round robin
Para configurar el balanceo de carga como round-robin, debes cambiar el
parámetro de balance a "roundrobin" en lugar de "weight". Aquí tienes cómo
hacerlo:
toml
[servers.http]
bind = ":80"
protocol = "tcp"
balance = "roundrobin" # Cambiado a roundrobin
max connections = 1000
client_idle_timeout = "10m"
backend idle timeout = "10m"
backend connection timeout = "2s"
[servers.http.discovery]
kind = "static"
static_list = [
    "192.168.10.9:80",
    "192.168.10.2:80",
    "192.168.10.3:80",
    "192.168.10.4:80",
    "192.168.10.5:80",
    "192.168.10.6:80",
    "192.168.10.7:80",
    "192.168.10.8:80"
]
```

Con esta modificación, el balanceador de carga distribuirá las solicitudes de manera equitativa entre los servidores backend en un ciclo round-robin. Cada solicitud se enviará al siguiente servidor en la lista, comenzando desde el principio después de alcanzar el último servidor.

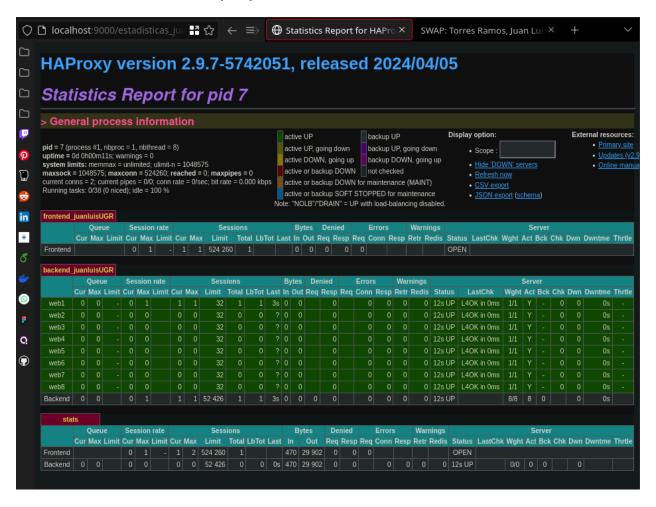
No sabía cómo aplicar la política. Chat gpt en este caso si acierta con la respuesta y aplica la política correcta. Para preguntas simples y directas chat gpt suele ser muy útil.

Tareas Avanzada - A4 Investigación y Pruebas de Tolerancia a Fallos

Vamos a iniciar la granja web con el balanceador haproxy, y allí vamos a pausar uno de los contenedores y a estudiar la reacción en el balanceador

Desplegamos con docker compose up -d y nos vamos directamente a las estadísticas del balanceador. Como describí anteriormente, se encuentra en http://localhost:9000/estadisticas juanluisUGR con usuario juanluisUGR y contraseña SWAP1234.

Estadísticas del balanceador haproxy



Las estadísticas actuales del balanceador las podemos ver directamente en docker-desktop



o podemos hacer docker stats < nombre contenedor>

```
docker stats
              p2-juanluis-haproxy-balanceador-haproxy-1
CONTAINER ID
               NAME
                                                            CPU %
                                                                         MEM
USAGE / LIMIT
                                                             PIDS
                  MEM %
                              NET I/O
                                                BLOCK I/O
22a253f90a88
               p2-juanluis-haproxy-balanceador-haproxy-1
                                                            0.14% 77.22MiB /
3.541GiB
           2.13% 57.2kB / 158kB
```

Podemos ver que el uso de CPU es muy bajo, de un 0,14%.

Ahora vamos a parar web6 con comandos o con docker desktop

```
docker stop p2-juanluis-haproxy-web6-1
```

Nos vamos a las estadísticas del balanceador (para la segunda imagen hemos de actualizar las estadísticas nuevamente:



Vemos que pasa de amarillo a rojo, de active UP, going down a active or backup DOWN.

Vamos a volver a ver las estadísticas a ver cómo ha afectado a nuestro balanceador



Al ser el uso en un principio del balanceador muy bajo, el impacto al quitar el servidor web6 es poco significativo, ha pasado de un 0,14% a un 0,12%.

Tareas Avanzada - A5 Automatización de escalado del escenario

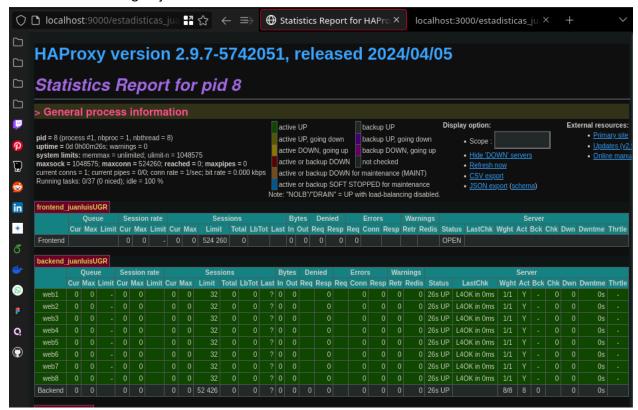
Vamos a implementar una lógica de escalado automático. En el caso planteado he creado un script donde al inicializarlo, primero comprueba si el uso de CPU es menor del 10%, suspende todos los servicios del backend a excepción de 1 y del balanceador para no usar toda la granja web, luego se pone a comprobar hasta 5 veces si no supera la carga de cpu de un 70%, si lo supera levantamos uno de los servidores web que hemos suspendido antes, el script es de la forma:

```
#!/bin/bash
# Escalado dinámico
# Contador máximo de contenedores web
max=1
times=0
# Definir el nombre del balanceador
balanceador="balanceador-haproxy-1"
$cpu2=$(docker stats --no-stream --format "{{.Name}} {{.CPUPerc}}" | grep
"balanceador" | awk '{print $2}' | sed 's/%//')
if ((cpu2 < 10)); then
   echo "Cerrando contenedores web por poca carga..."
   docker ps -q --filter "name=web" | grep -v "$(docker ps -q --filter
"name=${balanceador}")" | tail -n +2 | xargs -I {} docker stop {} >/dev/null
2>&1
fi
# Bucle principal
while true; do
   # Mostrar mensaje de comprobación
   echo "Realizando comprobación..."
   # Contadores web activos
   web=$(docker ps --format '{{.Names}}' --filter status=running | grep web)
   num_containers=$(echo "$web" | wc -w)
   # Monitorizar la CPU del balanceador
   cpu=$(docker stats --no-stream --format "{{.Name}} {{.CPUPerc}}" | grep
"balanceador" | awk '{print $2}' | sed 's/%//')
  # Valor crítico para la CPU
```

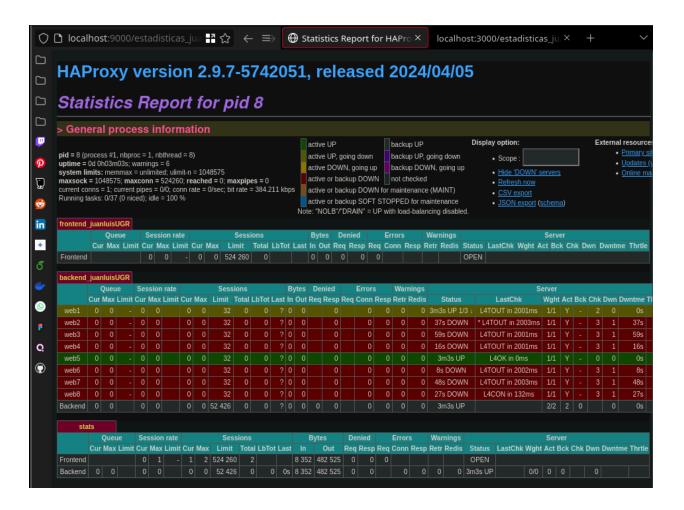
```
valor critico cpu=70
   # Mostrar información de La CPU
   echo "Uso de CPU: $cpu"
   echo "Valor Critico: 70"
   # Comprobar si la CPU es críticamente alta
   if (( $(echo "$cpu > $valor_critico_cpu" | bc -1) )); then
       echo "Necesito abrir un nuevo contenedor debido a la sobrecarga de la
CPU..."
       # docker compose up -d web 3
       #echo "docker-compose up -d web$((num_containers + 1))"
       #docker compose up -d web$((num_containers))
       if docker ps --format '{{.Names}}' | grep -q "web$num containers"; then
           echo "El servicio web$num_containers ya está en ejecución.
Aumentando la escala del servicio..."
           docker-compose up -d web=$((num_containers + 1))
       else
           echo "El servicio web$num_containers no está en ejecución. Iniciando
un nuevo contenedor..."
           docker-compose up -d web$((num containers + 0))
       fi
      times=0
   fi
   # Incrementar el contador de comprobaciones
  times=\$((times + 1))
   # Si se han realizado suficientes comprobaciones, salir del bucle
   if ((times >= 5)); then
      break
   fi
   # Esperar antes de realizar la siguiente comprobación
   sleep 10
done
echo "Escalado dinámico completado."
```

Para las métricas de monitoreo de CPU siempre me baso en docker Desktop, dentro del script hago llamadas a docker para ver el uso de la cpu por parte del balanceador.

Por último este sería un ejemplo de ejecución del script tenemos la granja web levantada



procedemos a ejecutar script (tenemos que darle permisos antes), lo primero que hace es, como el porcentaje de uso de cpu siempre va a ser bajo, va a suspender todos los servidores excepto el balanceador. En este caso queda up web5



3. ahora vamos a dar sobrecarga al balanceador con el comando en otra terminal, si está sobrecargado levantamos más servidores

```
ab -n 10000 -c 100 http://localhost:3000/
```

salida del script

```
./script.sh
Cerrando contenedores web por poca carga...
Realizando comprobación...
Uso de CPU: 0.07
Valor Critico: 70
Realizando comprobación...
Uso de CPU: 132.90
Valor Critico: 70
Necesito abrir un nuevo contenedor debido a la sobrecarga de la CPU...
El servicio web1 no está en ejecución. Iniciando un nuevo contenedor...
Recreating p2-juanluis-haproxy-web1-1 ... done
Realizando comprobación...
```

Uso de CPU: 112.53 Valor Critico: 70

Necesito abrir un nuevo contenedor debido a la sobrecarga de la CPU... El servicio web2 no está en ejecución. Iniciando un nuevo contenedor...

Recreating p2-juanluis-haproxy-web2-1 ... done

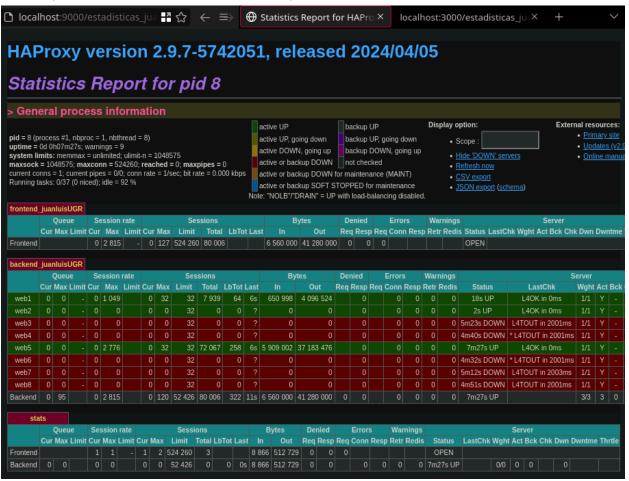
Realizando comprobación...

Uso de CPU: 0.16 Valor Critico: 70

Realizando comprobación...

Uso de CPU: 0.04 Valor Critico: 70

vemos que se levantan los servidores correspondientes



Este



Los picos que vemos de la cpu es cuando hemos ejecutado el comando de sobrecarga al balanceador.

cron a intervalo regulares para el script

1. ejecutamos el comando

crontab -e

2. agregamos el trabajo de nuestro script, para que se ejecute cada 2 minutos

*/2 * * * *

/home/torres/Documents/Github/Practicas_SWAP/Practica_2/P2-juanluis-haproxy
/script.sh

Análisis propuesta IA

Configura un trabajo cron que ejecute el script a intervalos regulares, por ejemplo, cada 2 minutos.

ChatGPT

Para configurar un trabajo cron que ejecute tu script a intervalos regulares, como cada 2 minutos, sigue estos pasos:

Abre tu terminal o consola de comandos.

Ejecuta el siguiente comando para editar el archivo de crontab: crontab -e

Si es la primera vez que ejecutas este comando, se te pedirá que elijas un editor de texto. Selecciona tu editor preferido.

Agrega la siguiente línea al final del archivo de crontab para ejecutar tu script cada 2 minutos:

javascript

*/2 * * * * /ruta/a/tu/script.sh

Asegúrate de reemplazar /ruta/a/tu/script.sh con la ruta completa hacia tu script.

Guarda y cierra el editor de texto.

Con esta configuración, el script se ejecutará automáticamente cada 2 minutos. Asegúrate de que el script tenga permisos de ejecución adecuados para que cron pueda ejecutarlo correctamente. Puedes modificar el intervalo de tiempo cambiando el valor 2 en la línea de cron por el intervalo deseado en minutos.

Para configurar el crontab solo le he tenido que preguntar a chat gpt para que me lo configure, una tarea que no requiere de mucho tiempo. Ahora para el script también he usado chat gpt pero he usado varios prompt para crear dicho script, además de las indicaciones que nos han dado en clases de prácticas. Con ello y a base de prueba y error he podido conseguir una solución funcional. He usado muchos prompt ya que no estoy muy informado con el temas de script y uso de docker. Si hubiese estado más informado, con chat gpt habría obtenido una mejor solución en un menor tiempo.